TP1 - Traitement Automatique des Langues
Pré-traitements avec spaCy

Introduction

Le pré-traitement constitue une étape importante de nombreuses applications de Traitement Automatique des Langues (TAL). Tokenisation, segmentation en phrases, normalisation, suppression des mots vides, lemmatisation ou encore étiquetage morpho-syntaxique permettent de transformer un texte brut en une représentation exploitable par les traitements ultérieurs.

Cependant, il n'existe pas de pipeline de pré-traitement universel. Une transformation peut améliorer une tâche et dégrader une autre. Par exemple, la lemmatisation peut réduire fortement la variabilité lexicale, mais faire perdre certaines distinctions morphologiques. La suppression des mots vides peut être utile pour certaines tâches statistiques, mais supprimer des informations importantes dans d'autres contextes. De même, une normalisation trop agressive peut modifier les résultats d'un analyseur morpho-syntaxique ou syntaxique.

Nous travaillerons sur les sous-corpus qui vous ont été fournis, en français et en anglais.

Objectifs pédagogiques :

À l'issue du TP, vous devrez être capables de :
- construire un pipeline spaCy ;
- comparer des stratégies de normalisation ;
- analyser les effets du pré-traitement sur un corpus ;
- personnaliser un pipeline ;
- évaluer une approche à base de règles ;
- mesurer le compromis entre qualité et coût computationnel.

1. Données et environnement de travail

Le TP sera réalisé en Python 3 avec la bibliothèque spaCy.

Les données sont disponibles à l'adresse : https://madoc.univ-nantes.fr/mod/resource/view.php?id=2292403

- SpaCy : https://spaCy.io/usage

Un notebook Colab vous est fourni. Vous devez compléter ce notebook.

Vous disposez de sous-corpus en français et de sous-corpus en anglais.

Attention : le travail d'analyse est à faire sur le corpus d'apprentissage.

Vous devez, dans un premier temps, lire l'article associé.

Votre rendu devra contenir une courte synthèse de cet article permettant notamment d'identifier :
- la problématique étudiée ;
- les données utilisées ;

- les principales caractéristiques des corpus ;
- les éventuelles particularités ou sources de bruit dans les données.

Installation

Vous utiliserez spaCy et les modèles linguistiques correspondant aux langues étudiées.

Documentation : https://spacy.io/usage

Modèles : https://spacy.io/usage/models

Vous choisirez vous-mêmes les modèles à utiliser pour le français et l'anglais et justifierez ce choix dans votre rapport.

2. Première exploration des données

Question 1 : Explorer les données

Pour chacun des sous-corpus, fournissez :

- le nombre de documents ;
- le nombre de phrases ;
- le nombre de mots/tokens ;
- la longueur moyenne des documents ;
- la longueur moyenne des phrases ;
- le nombre de formes distinctes (i.e. le dictionnaire de mots uniques).

Observez également plusieurs exemples de phrases et identifiez au moins deux phénomènes susceptibles de poser problème à un système de TAL.

Il peut s'agir, par exemple :

- de ponctuation atypique ;
- d'abréviations ;
- de chiffres ou de dates ;
- de majuscules/minuscules ;
- de mots composés ;
- de formes bruitées ou mal orthographiées.

3. Construire et analyser le pipeline

Question 2 : mise en place du pipeline

Construisez un pipeline spaCy permettant d'obtenir :

- la segmentation en phrases ;
- la tokenisation ;
- la lemmatisation ;
- l'étiquetage morpho-syntaxique (POS) ;
- l'analyse en dépendances.

Vous appliquerez le pipeline au sous-corpus français et au sous-corpus anglais.

Mesurez le temps d'exécution du pipeline sur chaque corpus.

Pour les traitements répétitifs, utilisez notamment les mécanismes permettant de traiter efficacement plusieurs documents (**nlp.pipe**).

Question 3 : normalisation

Comparez les représentations suivantes :

- texte original ;
- texte en minuscules ;
- texte lemmatisé ;
- texte soumis à une racinisation (stemming).

Pour chaque représentation, calculez le nombre de formes distinctes.

Analysez les différences et donnez quelques exemples de regroupements corrects ou incorrects.

Question 4 : mots-outils (*stopwords*)

Supprimez les mots vides et comparez les statistiques avant/après suppression.

Donnez un exemple de mot dont la suppression vous paraît pertinente et un exemple pour lequel elle pourrait être discutable.

Question 5 : ordre des traitements

Construisez et comparez deux configurations :

- Pipeline A : texte → tokenisation → POS tagging
- Pipeline B : texte → tokenisation → normalisation → POS tagging

Les annotations sont-elles identiques ?

Expliquez les différences éventuelles et indiquez où vous placeriez la normalisation dans un pipeline destiné à produire des annotations linguistiques.

Question 6 : dépendances

Utilisez le visualiseur de spaCy : https://spacy.io/usage/visualizers

À partir d'une phrase de votre corpus (en français), visualisez l'analyse syntaxique avec displacy.

Sélectionnez une phrase suffisamment représentative des données.

Visualisez son analyse en dépendances et discutez une analyse qui vous semble surprenante ou potentiellement erronée.

4. Personnaliser et évaluer le pipeline

Composant personnalisé

Vous allez maintenant créer votre propre composant de pipeline.

Implémentez un composant permettant de réaliser une normalisation à base de règles sur un phénomène présent dans les données (nombres, dates, abréviations…).

Le composant devra être intégré au pipeline avec **nlp.add_pipe**.

Documentation : https://spacy.io/usage/processing-pipelines

Question 7

Mesurez le temps du pipeline :

- sans votre composant ;
- avec votre composant.

Indiquez son surcoût et expliquez où vous placez votre composant dans le pipeline et pourquoi.

Analysez également son éventuel impact sur les tokens, les lemmes et les POS.

Règles vs information linguistique

Choisissez un phénomène pouvant être détecté :

- par un **Matcher** ou **PhraseMatcher** ;
- à partir d'une information linguistique produite par spaCy, par exemple les POS.

Construisez un petit jeu de test d'au moins 20 phrases, annotées manuellement.

Question 8

Calculez pour les deux méthodes :

- précision, rappel, F1-mesure ;
- temps d'exécution.

Comparez les deux approches.

Analysez quelques faux positifs et faux négatifs et expliquez les différences de performance.

Dans quelles situations privilégieriez-vous une approche à base de règles ?

5. Analyse globale des corpus

Vous allez maintenant comparer plusieurs représentations des corpus.

Construisez les versions suivantes :

- C0 : texte original ;
- C1 : texte normalisé et lemmatisé ;
- C2 : texte normalisé, lemmatisé et débarrassé des mots vides.

Question 9

Pour chacune des versions, calculez :

- nombre de tokens ;
- nombre de formes distinctes ;

- les trois mots les plus fréquents ;
- les trois bigrammes les plus fréquents.

Documentation : https://spacy.io/usage/rule-based-matching

Comment le pré-traitement modifie-t-il la structure statistique des corpus ?

Comparez également le sous-corpus français et le sous-corpus anglais.

Discutez les différences que vous observez et indiquez quelles différences peuvent être liées à la langue, au contenu des corpus ou au pré-traitement.

6. Rendu

Vous déposerez une archive .zip contenant :

- Une synthèse d'une demi-page maximum de l'article.
- Le notebook Colab complété, ou son export .ipynb. Les réponses aux questions devront se trouver dans le notebook.